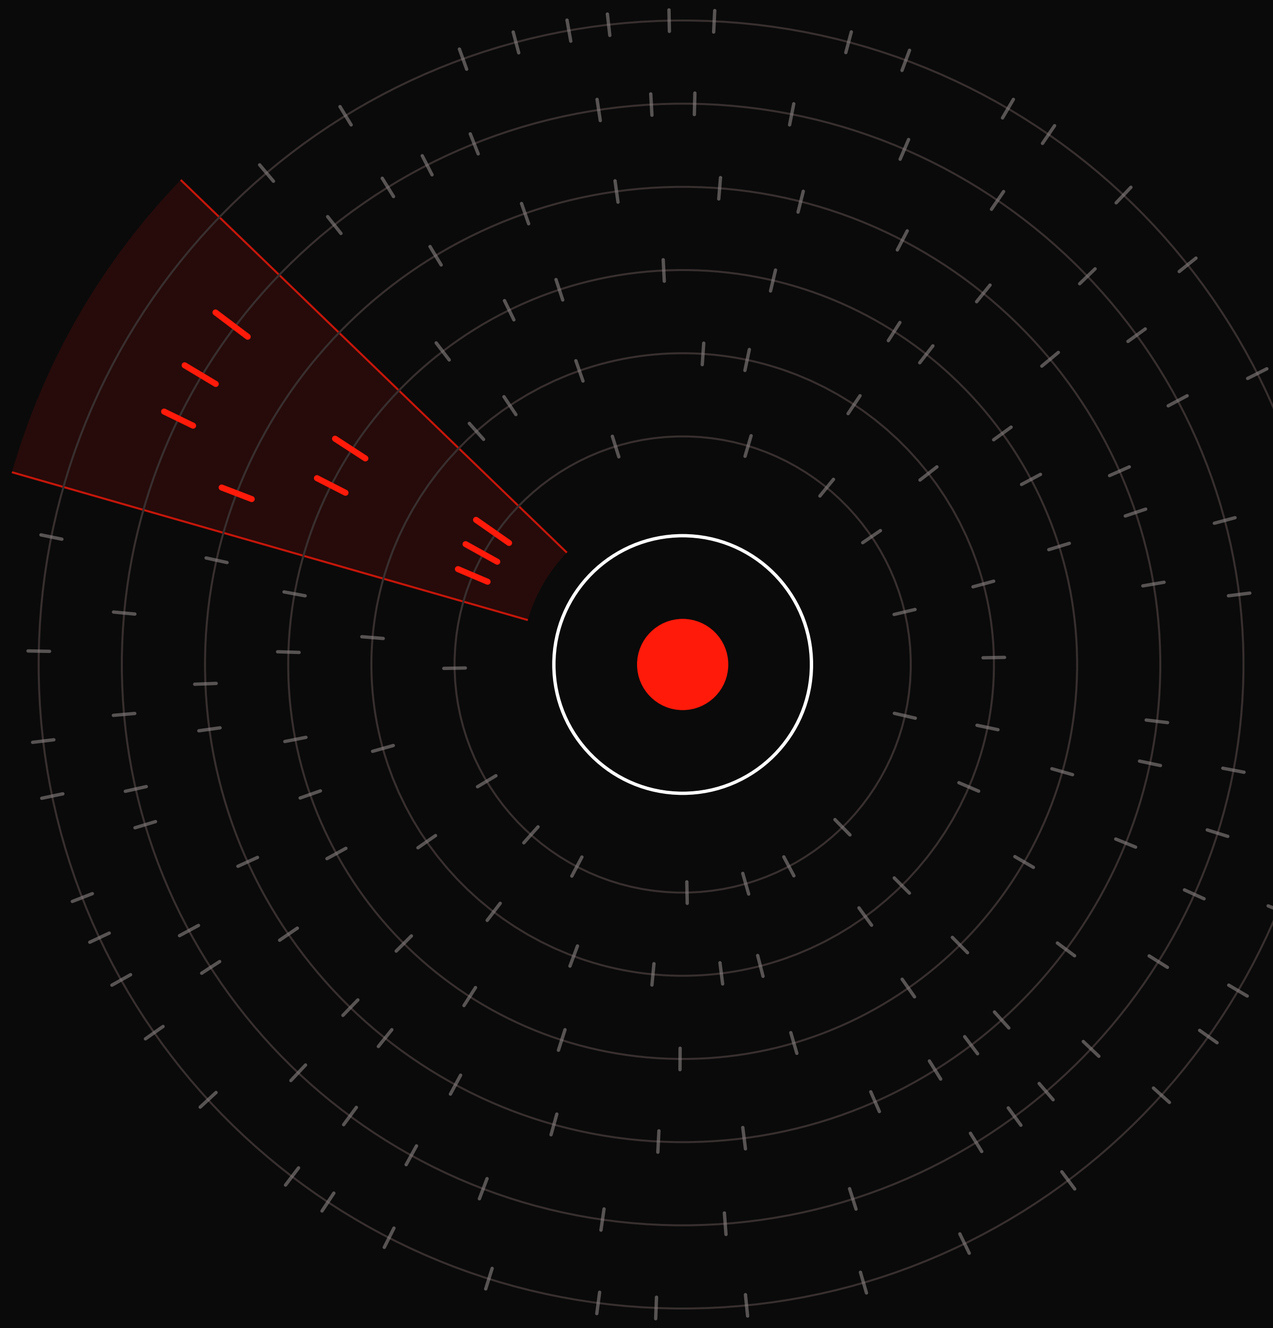
Globo × Inteli

Grupo 04

Vale a Pena Ver de Novo

Diagnóstico de degradação de streaming no Globoplay



Apresentação final da Sprint 5

Christian Santos, Diego Figueiredo, Gabriel Bartmanovicz, Livia Tavares,
Lorenzo Aggio, Luiz Borges, Nicole Neves e Vinicius Cadena

Globo × Inteli

Sprint 5

INTELI × GRUPO GLOBO

Argus

Investigar degradações de streaming com sinais integrados.



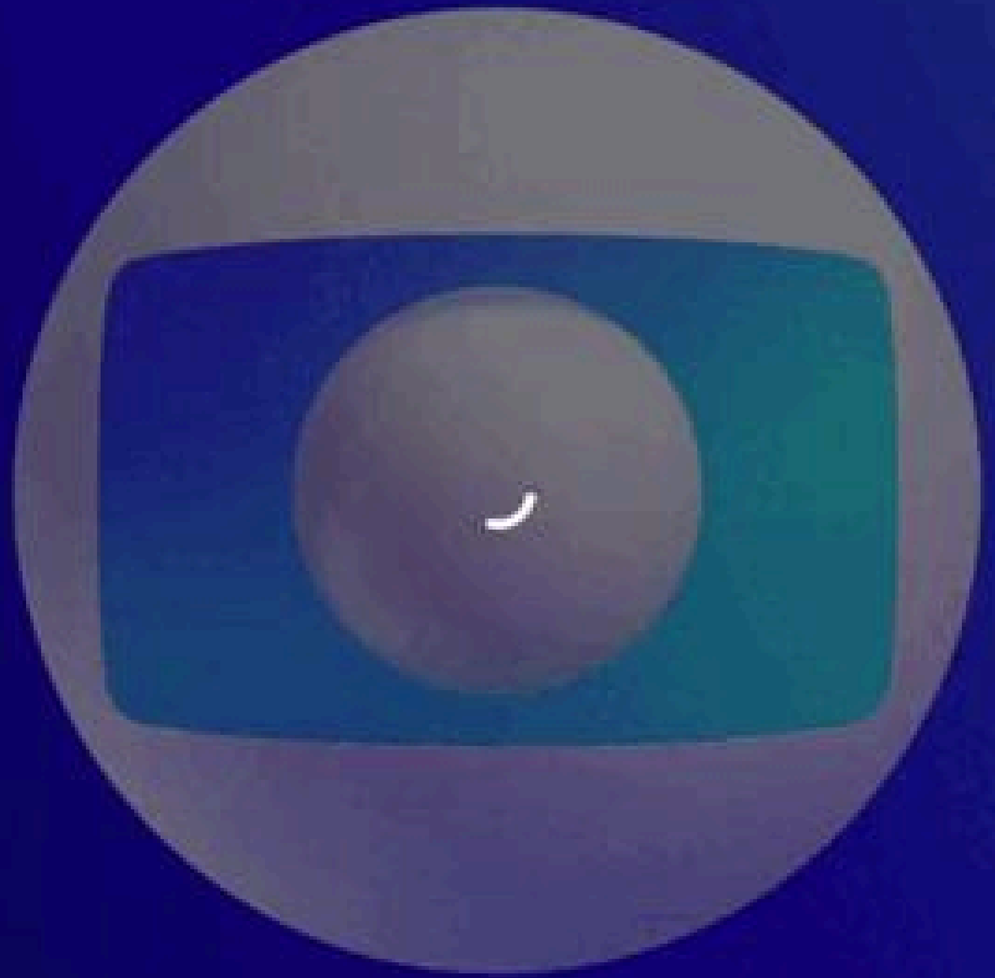
EQUIPE G04

Vale a Pena Ver de Novo

APRESENTAÇÃO

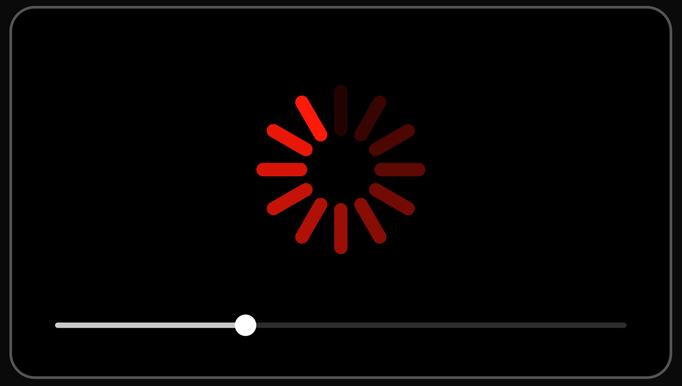
Sprint 5


globoplay




VALE A PENA
VER DE NOVO

Descobrir quem conserta leva mais tempo do que consertar.



Na TV do assinante

NPAW
Player QoE
sem alerta

Prometheus
CDN
sem alerta

New Relic
Backend
sem alerta

Apollo
Identidade
sem alerta

Tsuru
Deploy
sem alerta

ServiceNow
Incidentes
sem alerta

Cada área enxerga a sua parte. Ninguém enxerga a sessão inteira.

~30 mi
de usuários ativos por mês no Globoplay
EXAME, 2026

+5,8 p.p.
de abandono a cada segundo a mais para o vídeo começar
Krishnan e Sitaraman, IMC 2012

Linceu

Na mitologia grega, Linceu é o argonauta de visão tão aguçada que enxergava através de paredes de pedra. Daí os “olhos de lince”.

O nosso enxerga através dos silos.

Da degradação à causa provável, em minutos.

Sem depender de um especialista por componente.

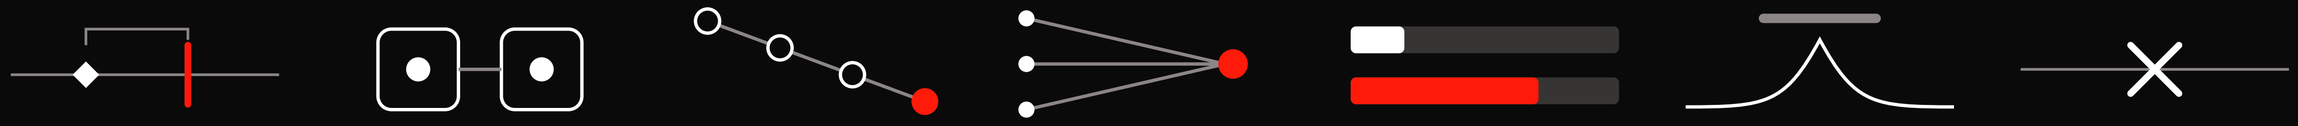


Seis fontes, um único eixo de tempo.

Causa provável, ranqueada
com as evidências e o recorte afetado

Uma anomalia sozinha não é hipótese.

Um detector acha o desvio. Onze famílias de regras procuram o que o confirma, e o que o desmente.



Temporal · **Semântica** · **Propagação** · **Entre fontes** · **Concentração** · **Contexto** · **Contrária**

O que as correlações encontram vira um score de seis fatores

Força da anomalia	Proximidade no tempo	Corroboração	Especificidade	Impacto	Qualidade
25	20	20	15	15	5

− 30 × contradição

Evidência contrária forte derruba a hipótese.

Publica com score ≥ 40 e cobertura ≥ 50%

O score ordena a investigação. Não é probabilidade.

Do deploy à hipótese em 17 minutos.

Exemplo ilustrativo da nossa documentação: uma regressão depois de um deploy no playback.



Hipótese gerada

Possível regressão após deploy no serviço de playback

84 **Confiança alta**

Cobertura de 100%

Força da anomalia	0,92
Proximidade no tempo	0,76
Corroboração	0,85
Especificidade	0,90
Impacto	0,70
Qualidade	0,95
Contradição	0,00

Não confirma o deploy como causa. Diz o que investigar primeiro.

Seis telas, na ordem da investigação.

Do primeiro sinal em desvio ao recorte afetado, sem trocar de ferramenta.

01 **Agora**
O que está degradado agora?

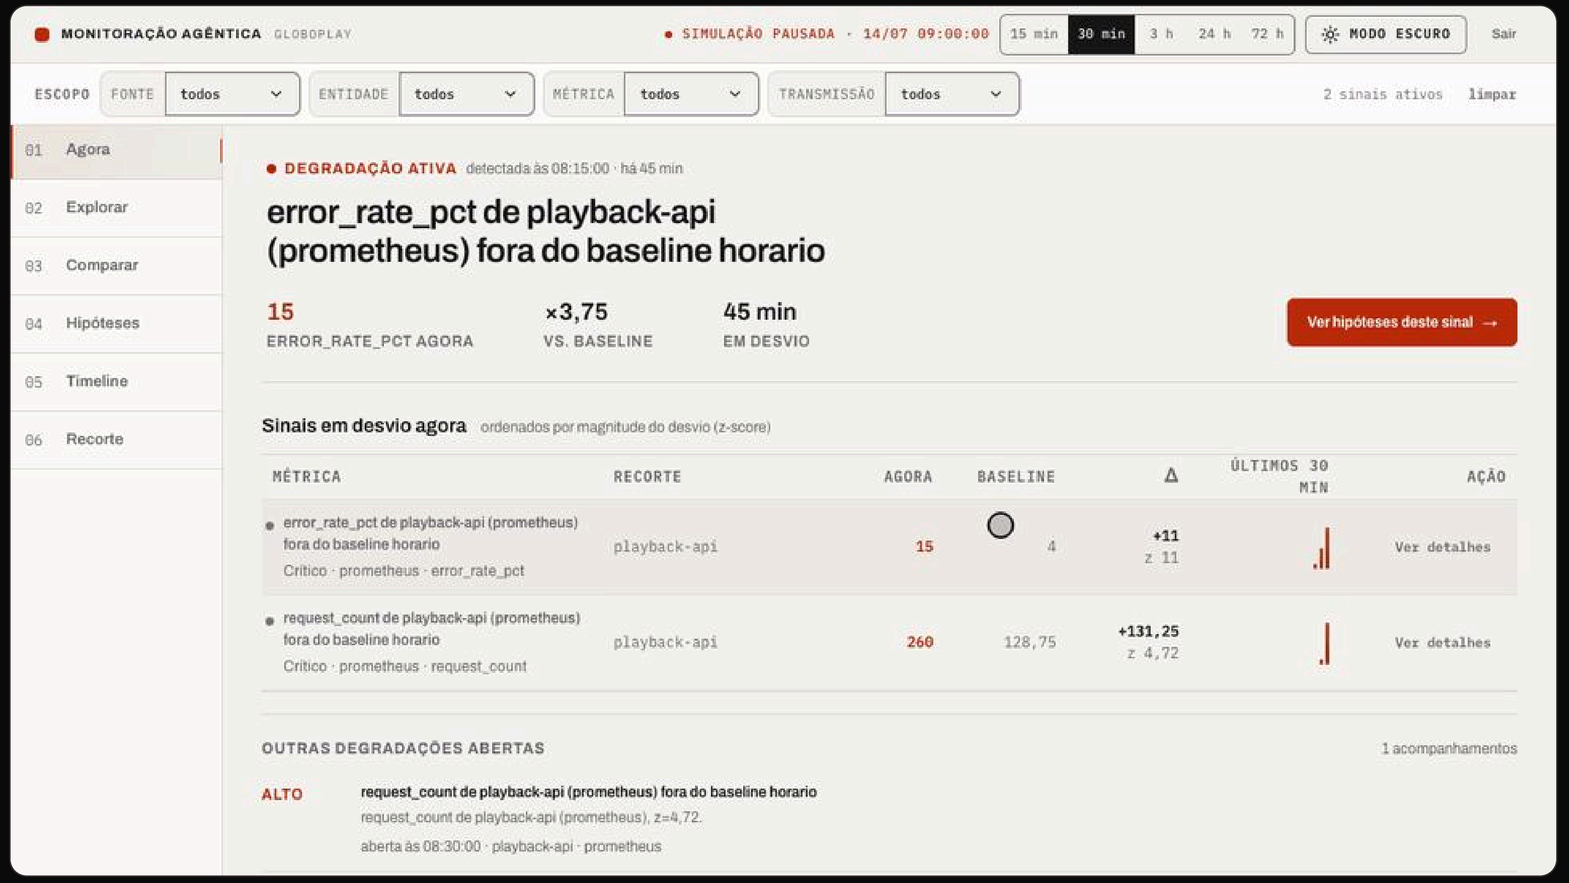
02 **Explorar**
Quando mudou, e onde se concentra?

03 **Comparar**
É anomalia ou é sazonalidade?

04 **Hipóteses**
Qual é a causa mais provável?

05 **Timeline**
O que aconteceu, e em que ordem?

06 **Recorte**
Quem foi afetado?



01 **Agora** O que está degradado neste momento?

Globo × Inteli

1 **Degradação ativa** valor, múltiplo do baseline e duração

2 **Sinais em desvio** ordenados pelo tamanho do desvio

3 **Atalho para a causa** leva o sinal às hipóteses

MONITORAÇÃO AGÊNTICA GLOBOPLAY

● SIMULAÇÃO PAUSADA · 14/07 09:00:00

15 min | 30 min | 3 h | 24 h | 72 h

Sair

ESCOPO | FONTE todos | ENTIDADE todos | MÉTRICA todos | TRANSMISSÃO todos | limpar

- 01 Agora
- 02 Explorar
- 03 Comparar
- 04 Hipóteses
- 05 Timeline
- 06 Recorte

1 ● DEGRADAÇÃO ATIVA detectada às 08:15:00 · há 45 min

error_rate_pct de playback-api (prometheus) fora do baseline horario

15	×3,75	45 min
ERROR_RATE_PCT AGORA	VS. BASELINE	EM DESVIO

3 Ver hipóteses deste sinal →

2 Sinais em desvio agora ordenados por magnitude do desvio (z-score)

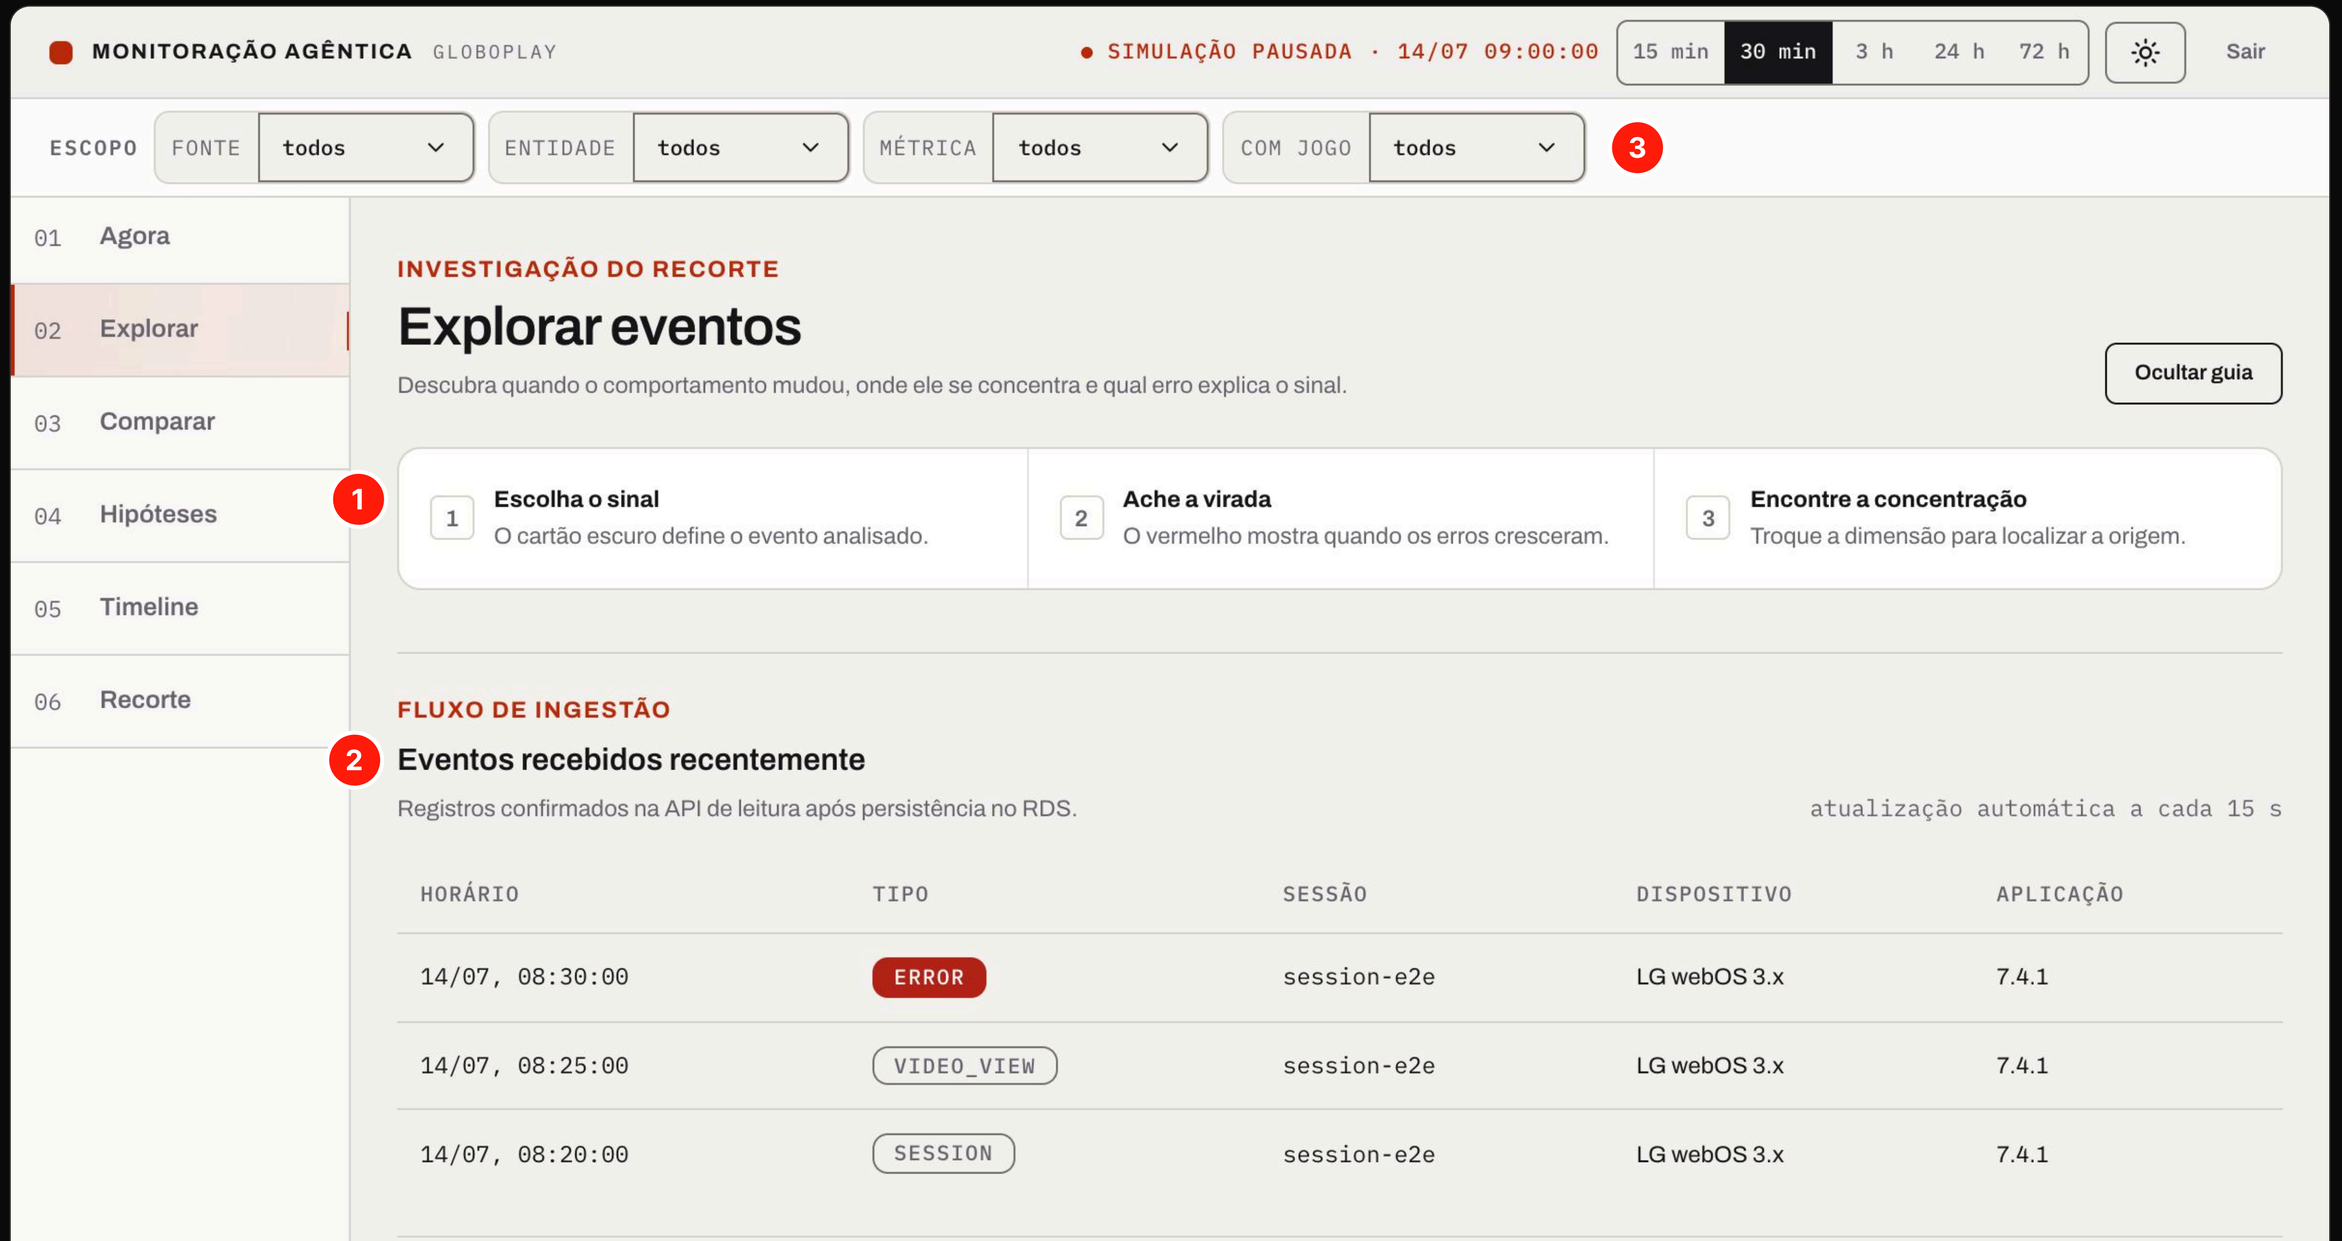
MÉTRICA	RECORTE	AGORA	BASELINE	Δ	ÚLTIMOS 30 MIN	AÇÃO
error_rate_pct de playback-api (prometheus) fora do baseline horario Crítico · prometheus · error_rate_pct	playback-api	15	4	+11 z 11		Ver detalhes
request_count de playback-api (prometheus) fora do baseline horario Crítico · prometheus · request_count	playback-api	260	128,75	+131,25 z 4,72		Ver detalhes

OUTRAS DEGRADAÇÕES ABERTAS — 1 acompanhamentos

02 # Explorar Quando mudou, e onde se concentra?

Globo × Inteli

1 **Guia em três passos** sinal, virada e concentração
2 **Eventos recebidos** confirmados pela API de leitura
3 **Filtros de escopo** fonte, entidade e métrica



03 Comparar — É anomalia ou é sazonalidade?

Globo × Inteli

1 **Quatro referências** de ontem ao último pico ao vivo
2 **Agora contra a referência** destaque acima de 50%
3 **O que mudou** eventos entre as duas janelas

MONITORAÇÃO AGÊNTICA GLOBOPLAY · ● SIMULAÇÃO PAUSADA · 14/07 09:00:00 · 15 min | 30 min | 3 h | 24 h | 72 h · Sair

ESCOPO

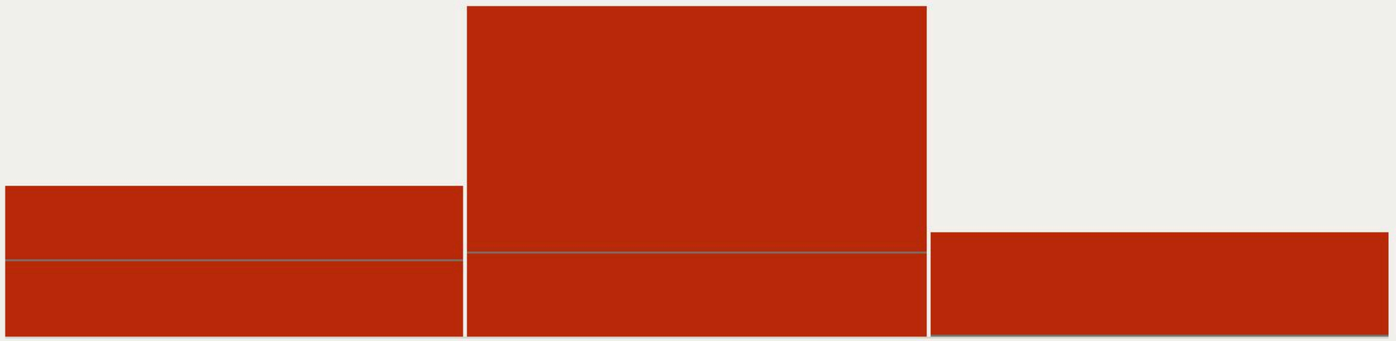
01 Agora
02 Explorar
03 Comparar
04 Hipóteses
05 Timeline
06 Recorte

Agora contra o passado

Mesmo escopo, mesma métrica, janela deslocada no tempo.

1 Ontem, mesmo horário | **Semana passada** 07/07 · 08:30–09:00 | Última janela estável | Pico ao vivo anterior

2 **Volume de eventos** contagem por bucket de 5 min



■ agora — semana passada ■ 50%+ acima da referência

3 O QUE MUDOU ENTRE AS JANELAS

08:38
deploy · globoplay-tv (time-player)

Só cobre deploy (fonte Tsuru) — autoscale e mudança de regra de WAF não têm dado discreto neste dataset.

MÉTRICA	AGORA	SEMANA PASSADA	Δ	VARIAÇÃO
				+271.4

04 Hipóteses

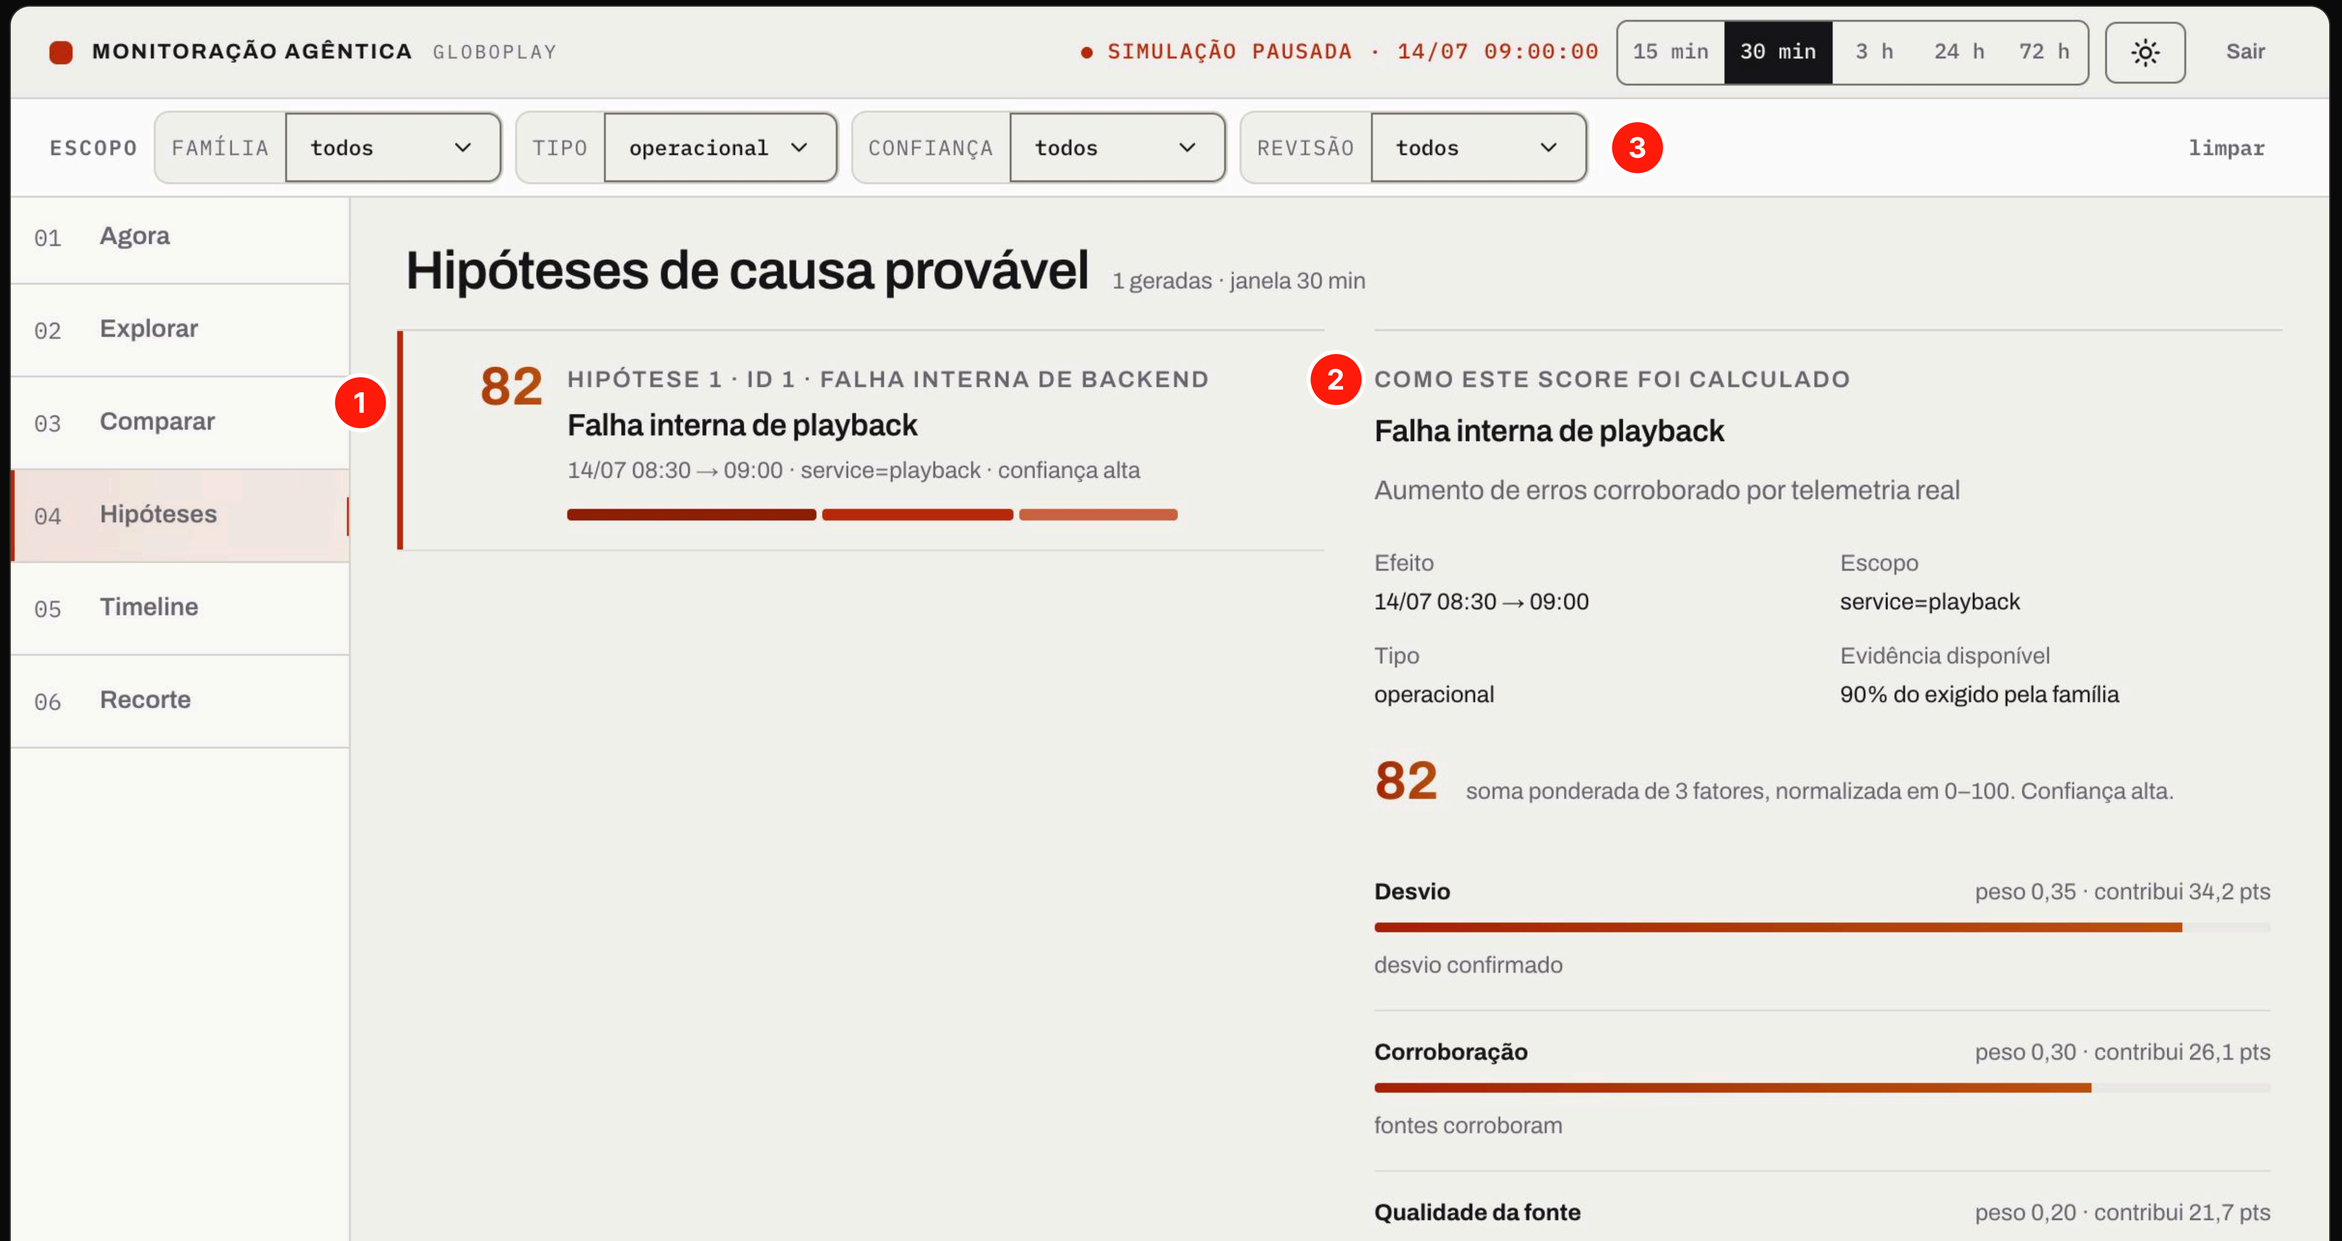
Qual é a causa mais provável, e por quê?

Globo × Inteli

1 **Lista ranqueada** por score, com família e confiança

2 **Score aberto** cada fator com peso e contribuição

3 **Filtros** família, tipo, confiança e revisão



05 Timeline

O que aconteceu, e em que ordem?

Globo × Inteli

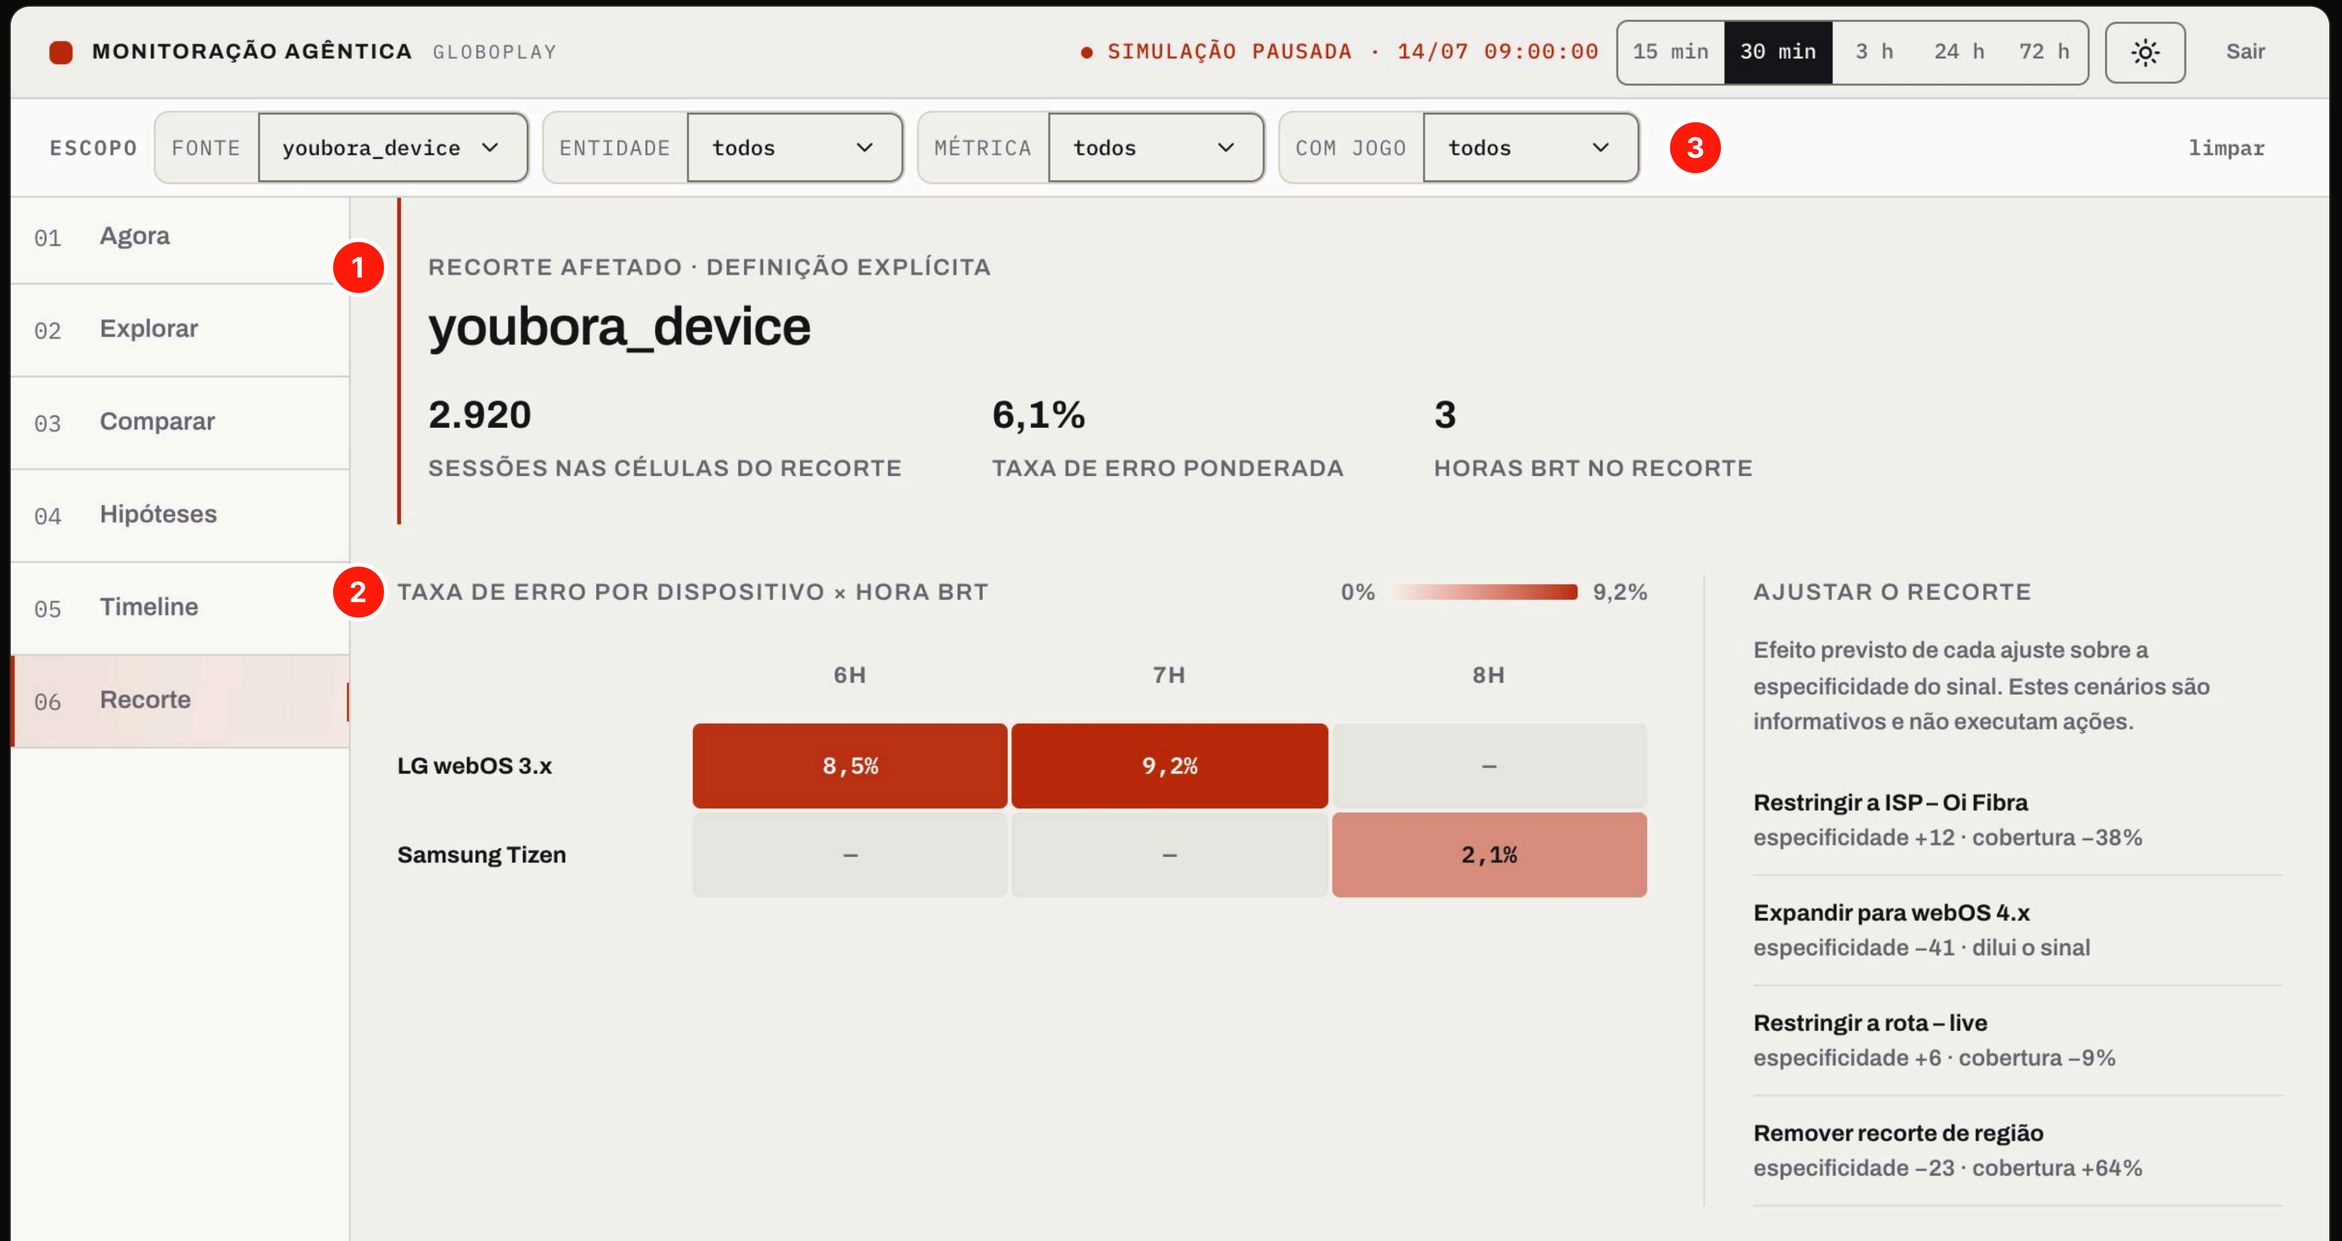
1. **Seis raias, um eixo** as fontes na mesma régua
2. **Janela de correlação** onde os sinais se encontram
3. **Deploy e incidente** eventos pontuais no mesmo eixo



06 Recorte — Quem foi afetado?

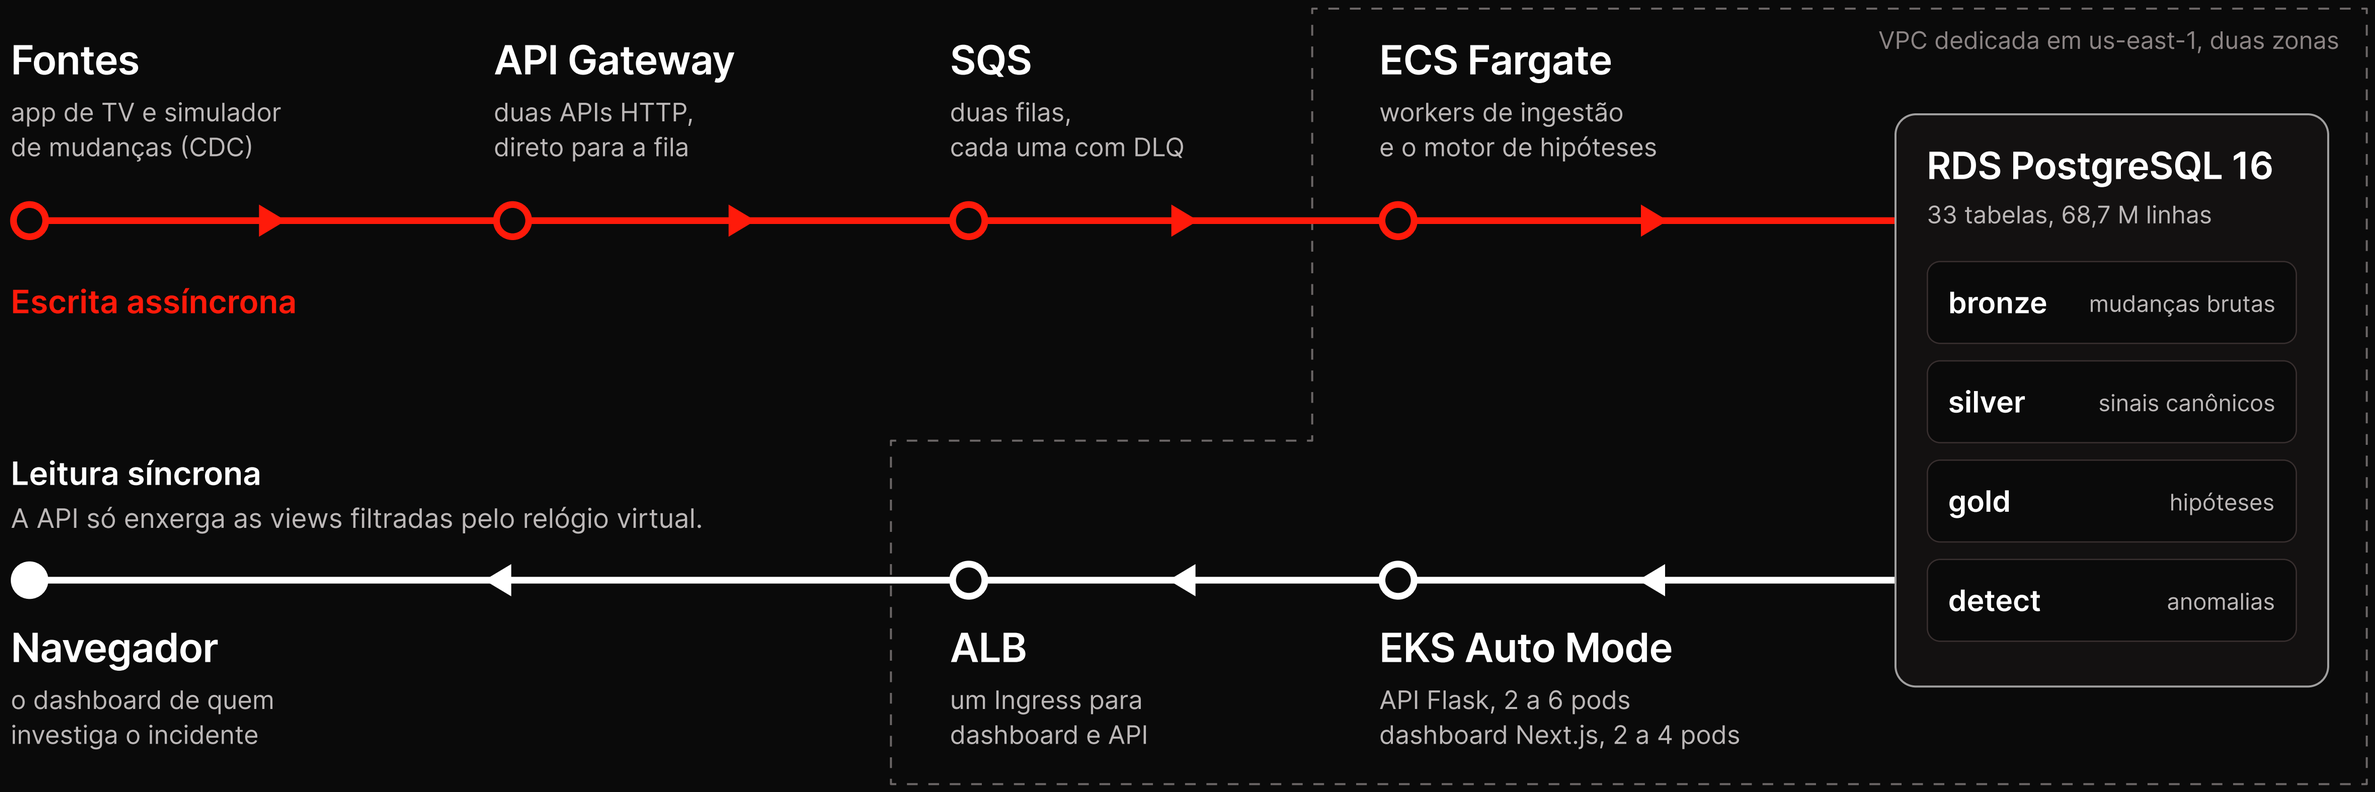
Globo × Inteli

1 **Recorte explícito** sessões, taxa de erro e horas
2 **Mapa de calor** erro por dispositivo e hora
3 **Escopo ativo** os filtros que definem o recorte



Dois caminhos, um banco.

A escrita passa por fila e absorve picos. A leitura roda em pods com autoscaling.



ECR
seis repositórios de imagens

CloudWatch e SNS
logs, métricas e alarmes

Secrets Manager
senha do banco

IAM
uma role por task

Terraform e Kustomize
infra e cluster como código

Testado para responder. Validado sob carga.

Funcionalidade, ingestão e leitura avaliadas em testes automatizados e ensaios de carga.

01 / FUNCIONALIDADE

217

testes automatizados aprovados

92 de frontend + 125 de worker.
Worker testado com PostgreSQL real.

02 / INGESTÃO

600 mil

eventos no maior lote

Drenagem em 5 min 46 s.
DLQ zerada nos quatro lotes.

03 / LEITURA NO EKS

200

usuários simultâneos

p95 das requisições: 841 ms.
0% de erros HTTP nessa rodada.

Três frentes validadas: funcionalidades, processamento em lote e consulta sob carga.

Mesmos fatos, dois investigadores.

Um agente de IA investiga o mesmo recorte que o motor, sem ver a resposta dele.

Primeira rodada

24 × 0

hipóteses em dado real: motor × agente

Diagnóstico

2 LLMs

o mesmo erro: o defeito era a ferramenta

Depois do conserto

~7 → 1

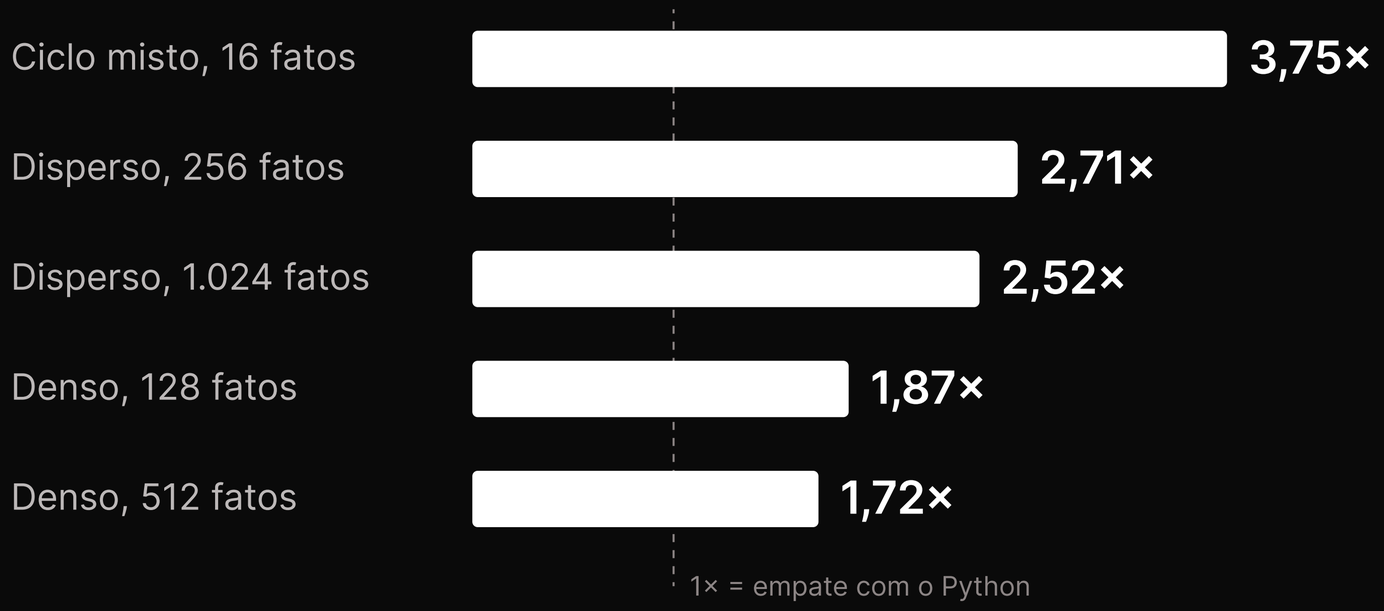
chamadas inválidas por execução

Ainda não mede qual abordagem é melhor.

LLM usado: qwen3-coder:30b, via Ollama.

Go calcula de 1,7 a 3,8 vezes mais rápido.

Reescrevemos o núcleo do motor em Go e exigimos saídas idênticas antes de medir.



Onde o Go perde

60% mais lento

no score da carga mais densa

1,54× a memória

na mesma carga

Evidência exploratória: ainda não justifica migrar.

Quanto custa manter o MVP?

Dois cenários para dimensionar o laboratório na AWS.

CENÁRIO BASE

US$ 351,48

por mês • 2 nós + US$ 40 em reservas

US$ 4.217,76 / ano

CENÁRIO AMPLIADO

US$ 494,48

por mês • 4 nós + US$ 110 em reservas

US$ 5.933,76 / ano

Mais capacidade: +US$ 143,00 por mês no cenário ampliado.

Estimativas do laboratório, operando 24/7. Valores e premissas detalhados na próxima página.

Orçamento estimado; validar com o consumo real no Billing.

De onde vem esse custo?

Composição do cenário base: US$ 351,48 por mês.

COMPOSIÇÃO MENSAL	US$ / MÊS
RDS PostgreSQL + 100 GB[1]	62,00
Workers no Fargate ARM	43,25
EKS • plano de controle (suporte padrão)	73,00
Rede • NAT + ALB + 3 IPv4	60,23
2 nós EC2 + Auto Mode[2]	73,00
Serviços auxiliares + tráfego[2]	40,00
TOTAL • CENÁRIO BASE	**351,48**

PREMISSAS

us-east-1 • 730 horas/mês

[1] RDS: estimativa histórica.
[2] Nós: US$ 0,05 por nó-hora; reservas a cotar.

Sem pessoal, impostos, LLM externo e alta disponibilidade de produção.

Confirmar inventário, consumo e capacidade no piloto.

Banco, rede e controle do EKS seguem cobrando mesmo com os workers desligados.

Fontes: README de infraestrutura e modelo de custos do projeto • AWS: EKS, Fargate, VPC e ALB (06/10/2026).

O que ainda falta provar.

Leitura sob carga

Otimizar as consultas ao banco

Ingestão

Sustentar 10 mil eventos por minuto

Motor de hipóteses

Calibrar os pesos com especialistas

Agente de IA

Medir o acerto em dado real

Go

Medir o ciclo completo, com banco

Produção

Duas zonas, rede privada e HTTPS

Vale a Pena Ver de Novo

Grupo 04, as oito pessoas por trás do Linceu.



Christian Santos



Diego Figueiredo



Gabriel Bartmanovicz



Livia Tavares



Lorenzo Aggio



Luiz Borges



Nicole Neves



Vinicius Cadena