ARGUS

SPRINT 05

Diagnóstico de degradação de streaming



Vale a Pena Ver de Novo

Grupo Globo + Inteli / G04 / Outubro de 2026

Um play travado, vários painéis

A pessoa vê o vídeo parar.
O plantão vê sinais espalhados.

Player	CDN	Backend	Identidade

A investigação precisa reunir o horário, o recorte afetado
e a evidência que sustenta uma causa provável.

Degradações de experiência também podem acontecer sem um erro explícito.

O que orientou as decisões

Valor

Oceano Azul e Canvas priorizam hipótese verificável, cobertura de legados e recorte do impacto.

Risco

A matriz destaca perda de dados, falso positivo, atraso de fontes e crescimento do custo.

Uso no plantão

As personas orientam uma investigação com filtros, comparação de janelas e linha do tempo.

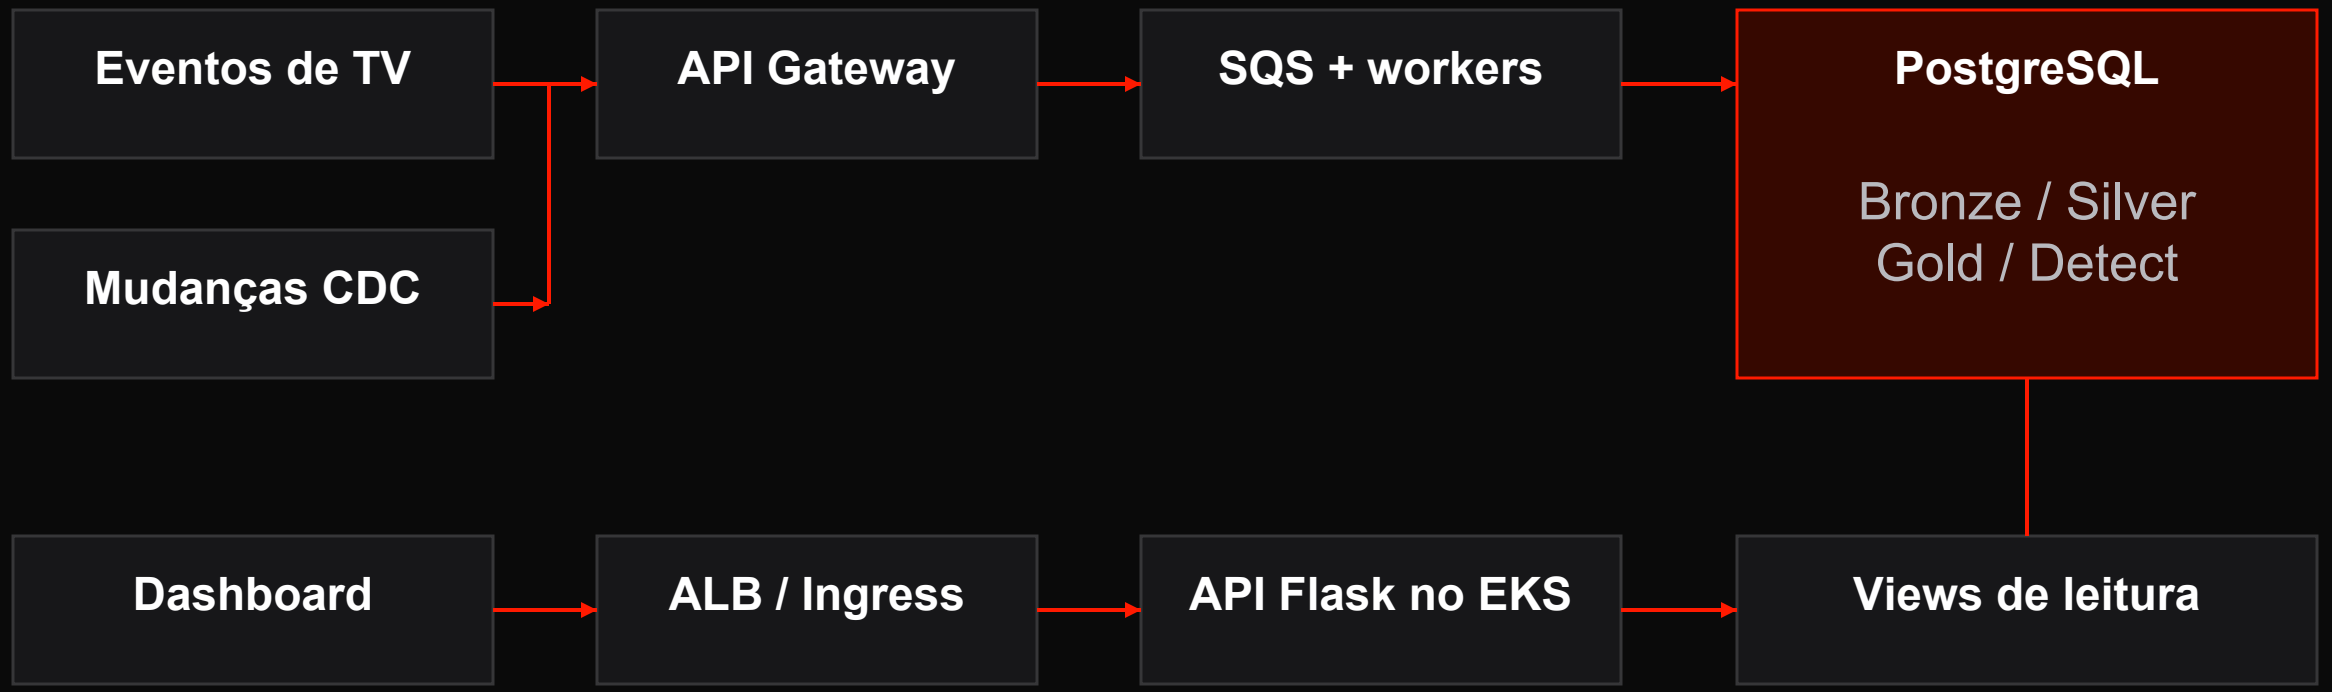
Essas análises orientaram o desenho. A validação de desempenho veio depois, nos ensaios.

Perguntas que a solução responde

Pergunta do plantão	Resposta do Argus	Alcance
Onde aparece a degradação?	Sinais, filtros e recortes do dashboard	Implementado
O que mudou antes do efeito?	Timeline e comparação de janelas	Implementado
Quais causas são plausíveis?	11 famílias e evidências ranqueadas	Motor testado
Quais anomalias podem gerar incidentes?	Desvios do baseline e contexto	Sem garantia preditiva

A causa permanece candidata e exige revisão humana. O ganho no tempo de diagnóstico ainda precisa de medição.

Arquitetura para uma investigação comum



Disponibilidade temporal: as views respeitam available_at ≤ sim.now().

Três caminhos de ingestão

Origem	Caminho de escrita	Garantia principal
Eventos de TV	Gateway, SQS, event worker, bronze.event	Validação e deduplicação
CDC simulado	Gateway, SQS, merge worker, change_log	Log + MERGE transacional
CSV / Parquet	File API, fila no Postgres, file worker	Lease, fencing e rollback

O loader prepara a base histórica via COPY antes da ingestão incremental.

Upload de arquivos: implementação e testes locais. A publicação na AWS ainda está pendente.

Python no MVP, Go como alternativa

Critério	Python, implementação atual	Go, alternativa
Integração	Reutiliza contratos, ETL e regras existentes	Exige portar contratos e testes
Concorrência	Processos do gunicorn e espera de I/O	Goroutines e channels
Evolução do motor	Regras e análise no mesmo ecossistema	Serviço dedicado possível
Decisão do projeto	Preservar o MVP e medir o gargalo	Avaliar com o mesmo ensaio

Não há benchmark Go versus Python no projeto. Os gargalos observados não justificam, sozinhos, uma reescrita.

Hipóteses com evidência e contradição



Exemplo ilustrativo

Um deploy precede o aumento de erros.
Outra fonte corrobora o desvio.
Uma evidência contrária reduz a confiança.

Score e cobertura

Evidências disponíveis normalizam o score. Contradições reduzem a confiança.

Correlação temporal sustenta uma candidata. A confirmação da causa continua humana.

Motor, refinador e agente de investigação

Motor atual

11 famílias determinísticas. Score explicável, cobertura e evidências. Implementado e testado.

Ollama opcional

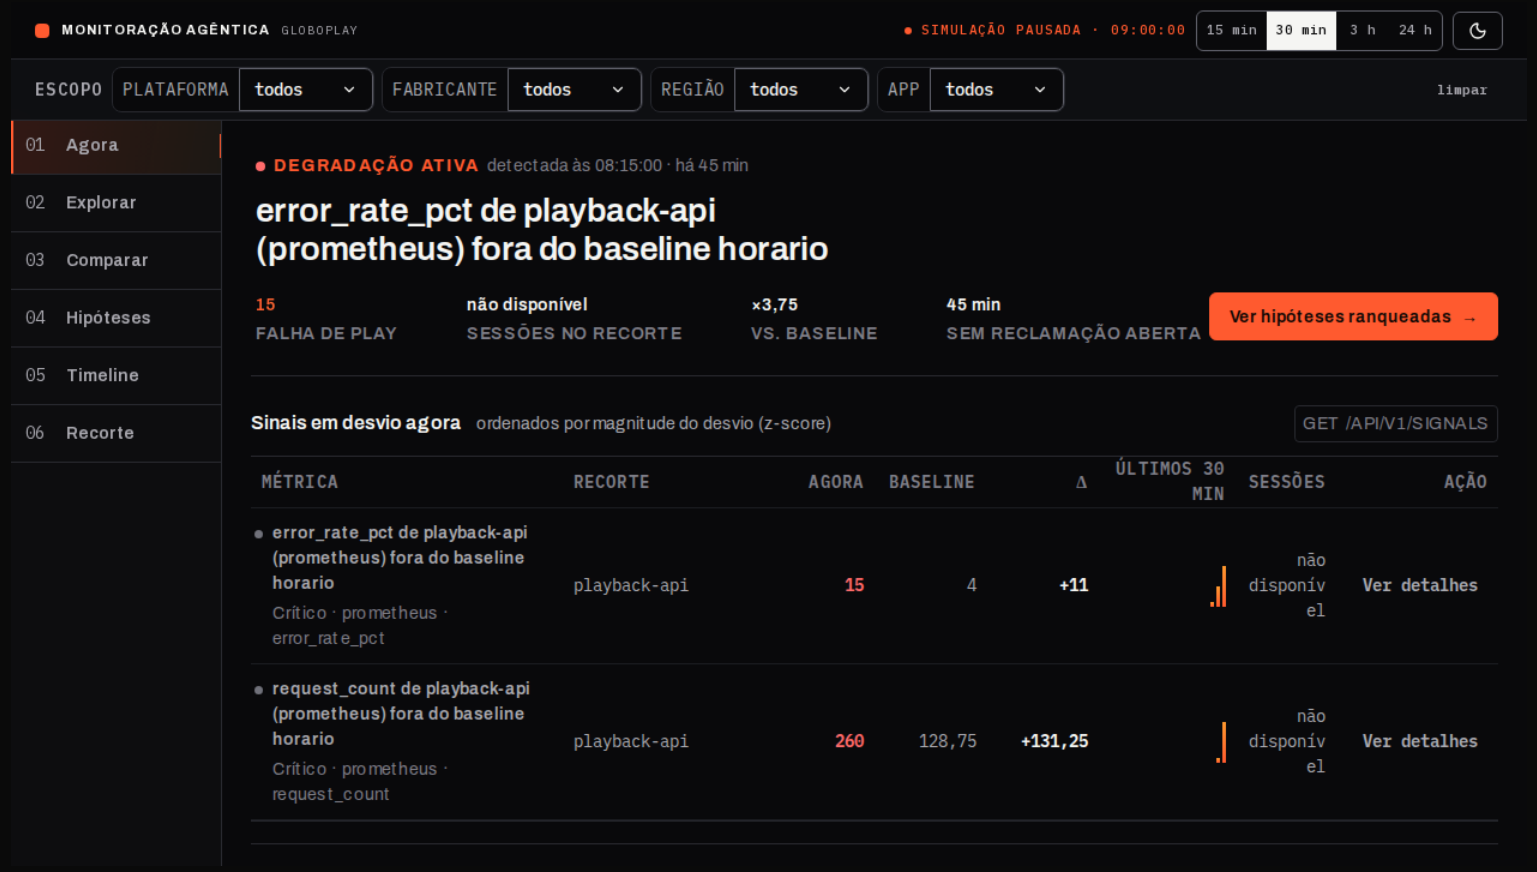
Refina o texto de uma hipótese publicada. Resposta com fontes. Sem validação no EKS.

Agente proposto

Investiga fatos de um checkpoint e procura contradições. MVA experimental ainda não publicado.

LLM: configurável em OLLAMA_MODEL. O repositório não comprova um modelo específico em execução.

MVP: o recorte da degradação



Captura histórica da interface

Uma janela de investigação

Filtros do recorte

Desvio do baseline

Acesso às hipóteses

MVP: upload de CSV e Parquet



O servidor valida o arquivo completo e informa inseridos, duplicados e rejeitados.

92
testes frontend

125
testes worker com Postgres

50 MiB
limite por arquivo

Evidências locais de 05/10. A imagem final e os novos Deployments ainda precisam de execução.

Implantação híbrida na AWS

EKS Auto Mode

API de leitura e frontend. Deployments, probes, HPA, PDB e Ingress com ALB.

ECS Fargate

Ingestão e processamento assíncronos. IAM por task para acesso a filas e armazenamento.

PostgreSQL 16

Camadas compartilhadas. Views com controle temporal e usuário de leitura restrito.

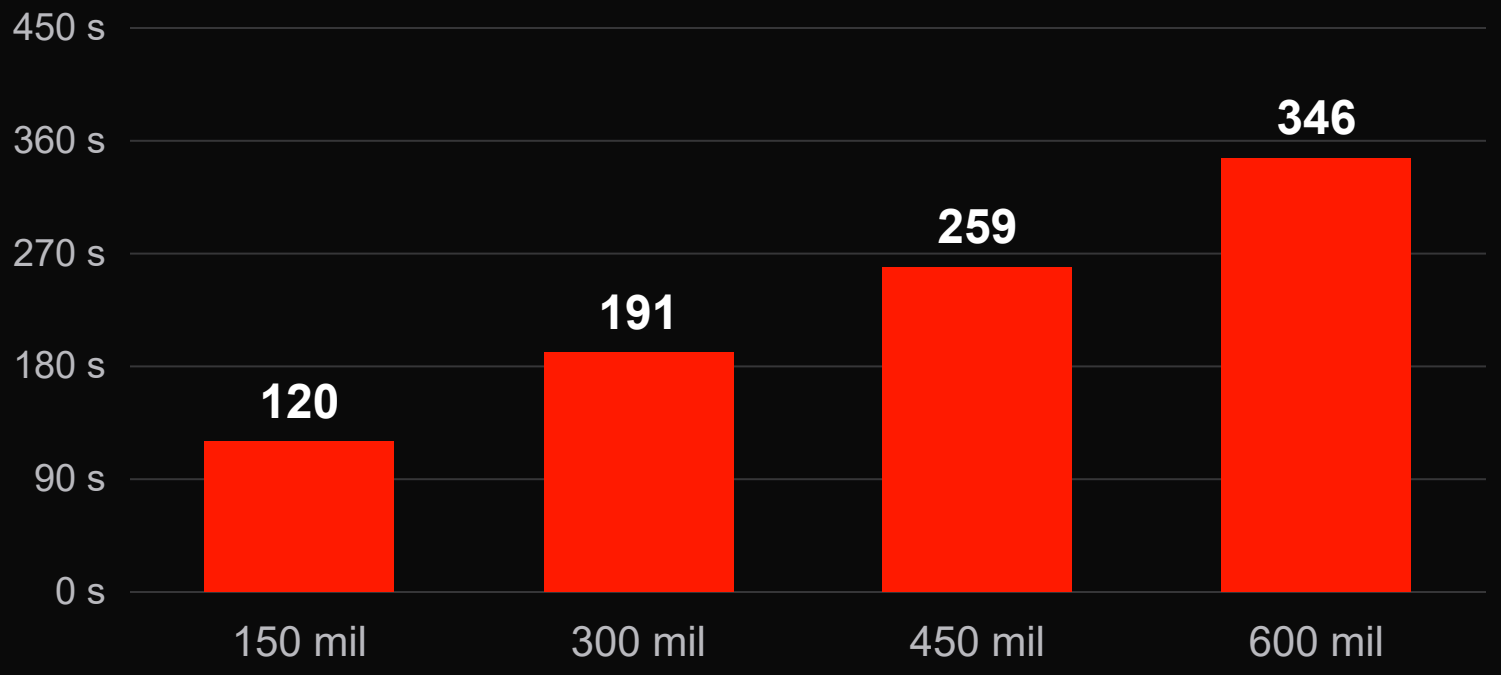
Terraform + Kustomize + Job de migrations. Single-AZ, NAT único e distribuição dos pods limitam a disponibilidade.

Condições de teste e alcance

Ensaio	Ambiente e carga	O que comprova
Ingestão	AWS, k6, 150 mil a 600 mil eventos	Aceite, drenagem, contagem
Dashboard	EKS, 5 / 25 / 100 VUs, 6 min	Latência e limiares por tela
Resiliência	kind, 1 nó, k6 com 5 VUs	Pods, probes e rollback
Arquivos	Local, dados sintéticos e Postgres	Contrato, dedup e transação

Dados de simulação e ensaios controlados. Nenhuma rodada demonstra MTTR menor em produção do parceiro.

Ingestão: quatro lotes em 5 min 46 s



1,5 milhão

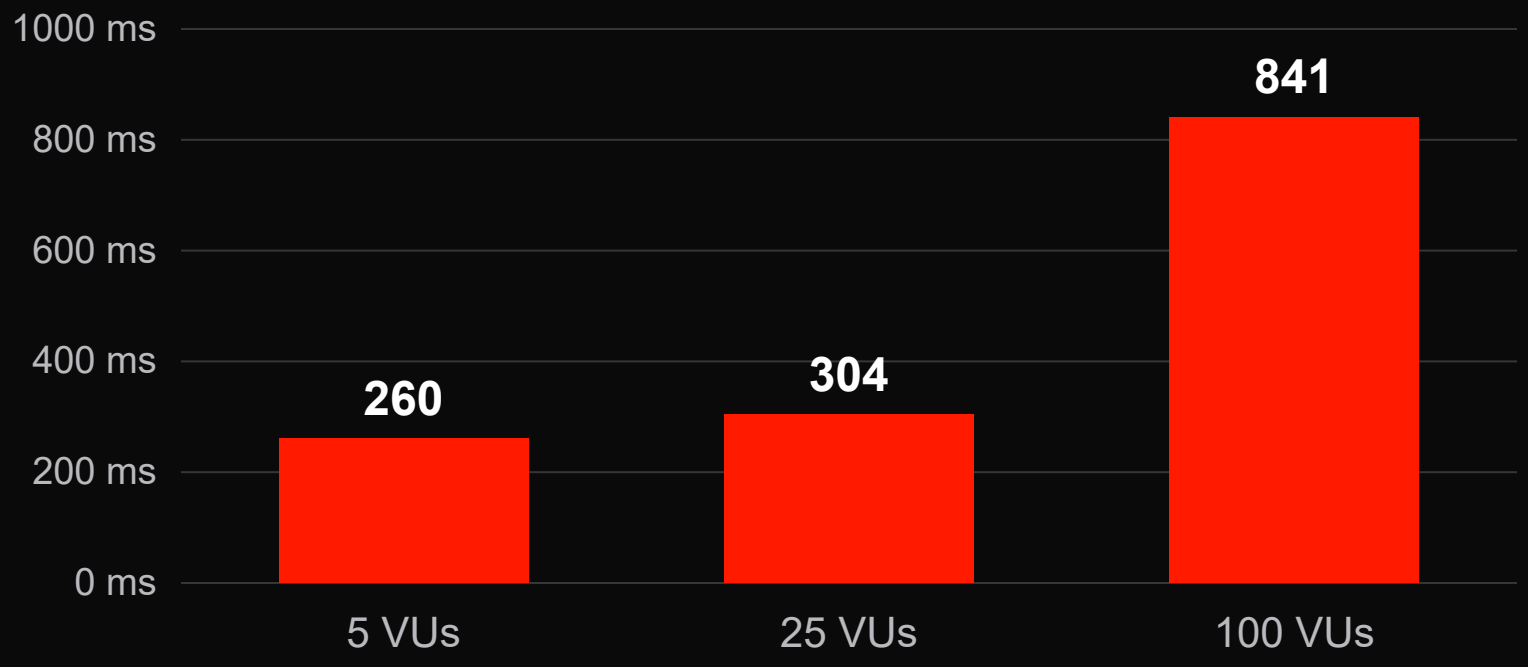
eventos reconciliados na rodada de 09/09

104 s

de margem no pior lote para o limite de 450 s

Zero erro no aceite e DLQ zerada. A fila drenada ainda não garante frescor na consulta.

Dashboard: 100 usuários, p95 de 841 ms



0%

erros nos três níveis

969 ms

p95 da abertura de tela
no nível de 100 usuários

24/09, gerador fora da VPC. HPA com métrica válida, sem aumento de réplicas observado.

A saturação revelou o limite do ensaio

Usuários	p95 das requisições	Erros	Critérios por tela
200	2.766 ms	0%	Reprovado
450	9.486 ms	15,21%	Reprovado
900	30.001 ms	24,80%	Reprovado

Entre 100 e 200 usuários no ensaio com duas réplicas

21/09: HPA sem metrics-server. A rodada de 24/09 corrigiu as métricas, mas não repetiu a saturação.

Resiliência: a segunda réplica fez diferença

Falha controlada	Resultado observado	Leitura
Excluir pod, 1 réplica	8,3 s até Ready, 14,3% de falhas	Sem capacidade reserva
Excluir pod, 2 réplicas	6,2 s até Ready, zero falhas	Outra réplica atende
Imagem inexistente	Pods antigos atendem, undo em 3 s	Rollback manual
Banco indisponível	Readiness retira pod, zero reinício	Dependência isolada

kind local, um nó, 24/09. Recuperação de nós, zonas e RDS na AWS ainda precisa de ensaio.

Gargalos que ainda limitam a solução

38 min 32 s

até o último evento aparecer na API
Amostra única de um lote de 150 mil

Frescor

Separar o bootstrap histórico do watermark incremental e medir o p95 completo.

Capacidade

Repetir a saturação com HPA ativo e observar aumento real de réplicas.

Disponibilidade

Distribuir pods e nós. Ensaiar RDS, perda de nó e recuperação na AWS.

Custo: US$ 106 não cobre o desenho atual

Componente	Premissa mensal	US$ / mês
RDS + 100 GB	Estimativa histórica do repositório	62,00
Fargate ARM	1,5 vCPU + 3 GB, 730 h	43,25
EKS, plano de controle	Suporte padrão, US$ 0,10/h	73,00
NAT + ALB + IPv4	Horas e 3 IPv4, sem uso variável	60,23
Subtotal parcial	Nós EKS e tráfego ainda por somar	238,48

Estimativa para 730 h em us-east-1. Inclui uma premissa histórica de RDS e exclui créditos e impostos.

Orçamento ampliado e sensibilidade

Item	Base, 2 nós	Ampliado, 4 nós
Subtotal parcial	238,48	238,48
Nós EKS + Auto Mode, premissa	73,00	146,00
Reserva de serviços auxiliares	30,00	60,00
Reserva de uso variável	10,00	50,00
Orçamento mensal, US$	351,48	494,48

Nós: provisão de US$ 0,05 por nó-hora, ainda a cotar. Segundo NAT + IPv4: +US$ 36,50/mês, antes do tráfego.

Custo por evento e valor operacional

US$ 351,48

por milhão, se o mês tiver 1 milhão
de eventos válidos persistidos

US$ 35,15

por milhão com 10 milhões
e o mesmo orçamento

Retenção

10 milhões × 1 kB = 10 GB/mês
90 dias = 30 GB, antes de índices e WAL

302 h/ano

potencial de economia de
plantão
Hipótese: redução de 35%

Capacidade para 10 milhões/mês e economia de plantão são hipóteses. LLM, pessoal e impostos ficam fora do orçamento cloud.

TCO: a viabilidade depende da adoção

TCO em 3 anos, R$ milhões	Base acadêmica	Cenário pessimista
Manter o contrato assumido	12,192	12,192
Construir + operar + residual	11,365	13,562
Economia estimada	0,827	-1,370

6,8% economia no cenário base
Virada acumulada perto do mês 25

Premissas sem validação do parceiro: contrato de R$ 4,064 mi/ano, substituição de 50% e rollout de 40% / 80% / 100%.

Conclusão: MVP funcional, evolução condicionada

O Argus reúne sinais e apresenta causas candidatas verificáveis.

Comprovado

Ingestão e leitura sob carga
Motor determinístico testado
Upload validado localmente

Próximo aceite

Frescor medido ponta a ponta
Escala e recuperação na AWS
Custo e valor com dados do parceiro

O piloto deve medir tempo até hipótese útil, evidência correta e custo por evento persistido.

ARGUS

OBRIGADO!



Vale a Pena Ver de Novo

G04 / Grupo Globo + Inteli

Apêndice: rastreabilidade dos resultados

Tema	Documento no repositório
Arquitetura e recuperação	artefatos/arquitetura-final.md
Carga e Kubernetes	artefatos/testes-funcionais.md
Lotes e frescor	artefatos/testes-carga-inicial.md
Upload, corte 05/10	artefatos/plano-ingestao-arquivos.md
Premissas de TCO	artefatos/entendimento_negocio.md

Preços oficiais AWS e fontes por slide nas notas. Corte do projeto: 06/10/2026, base f3c498e.